


UNIVERSIDAD NACIONAL FEDERICO VILLARREAL

FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS

**SIMULACIÓN DE EVENTOS DISCRETOS PARA EL ANÁLISIS Y
MEJORA DE LA CAPACIDAD DE ATENCIÓN DE UN CENTRO DE
LLAMADAS , 2026**

Trabajo Final del Curso de
Simulación de Sistemas



Equipo N.º 7 :

Integrantes:

[Barboza Chaname Juan Carlos]

[Yacila Lopez Victor Daniel]

[Guillen Sanchez Omar Bruno]

Docente

Mg. Maurice Frayssinet Delgado

Lima – Perú

2026

ÍNDICE

2. Resumen ejecutivo	4
3. Introducción	4
4. Planteamiento del problema	5
5. Objetivos	7
5.1. Objetivo general	7
5.2. Objetivos específicos	7
5.3. Alcance del modelo	8
5.4. Exclusiones	8
5.5. Restricciones	8
5.6. Criterios de éxito	9
6. Alcance y frontera del sistema	9
6.1. Elementos incluidos	9
6.2. Elementos excluidos	9
6.3. Interacciones con el entorno	10
6.4. Justificación de los límites	10
7. Descripción del proceso seleccionado	10
8. Modelo conceptual	11
9. Diagrama BPMN AS-IS	13
9.1. Actores (carriles) del proceso	13
9.2. Fases del proceso	14
9.3. Diagrama	15
10. Datos utilizados	16
10.1. Fuente de los datos	16
10.2. Estructura del dataset	16
10.3. Preparación de datos derivados	17
10.4. Verificación de calidad de los datos	17
11. Análisis estadístico de datos	18
11.1. Estadística descriptiva general	18
11.2. Evolución mensual del cumplimiento del SLA	21

11.3. Nota sobre calidad de los datos	22
12. Distribuciones seleccionadas	23
12.1. Criterio descriptivo: media frente a desviación estándar	23
12.2. Prueba de bondad de ajuste (Kolmogorov-Smirnov)	23
12.3. Distribuciones finales adoptadas	24
13. Modelo computacional	25
13.1. Enfoque y herramientas	25
13.2. Parámetros del modelo AS-IS	25
13.3. Resultado de una corrida de demostración	26
13.4. Ejecución de réplicas	27
14. Verificación y validación del modelo	27
14.1. Resumen de supuestos y limitaciones	30
15. Resultados del escenario AS-IS	33
16. Escenarios What-If	35
17. Propuesta TO-BE	36
17.1. Diagrama BPMN del proceso TO-BE	38
18. Comparación AS-IS versus TO-BE	39
18.1. Indicadores antes y después	39
18.2. Impacto en tiempos de espera	40
18.3. Impacto en utilización	40
18.4. Impacto en throughput	41
18.5. Viabilidad de implementación	41
18.6. Recomendación final	41
19. Conclusiones	42
20. Recomendaciones	43
20.1. Recomendaciones operativas para la organización	43
20.2. Recomendaciones para extender el modelo en trabajos futuros	43
21. Bibliografía	44
22. Anexos	44

2. Resumen ejecutivo

Este trabajo analiza el deterioro del nivel de servicio de un call center de cuatro agentes durante el año 2021, mediante un modelo de simulación de eventos discretos construido con las herramientas y técnicas desarrolladas en el curso Simulación de Sistemas. El call center registró 51 708 llamadas a lo largo del año; mientras el volumen mensual se duplicó (de 3 000 llamadas en enero a 6 249 en diciembre), el porcentaje de llamadas atendidas dentro del estándar de servicio (90% en 60 segundos o menos) cayó de 97.47% a 83.45%, y el tiempo de espera promedio se multiplicó por más de seis veces.

Se construyó un modelo computacional que representa el proceso de atención (llegada, cola, atención y cierre de llamadas) con distribuciones Exponenciales para el tiempo entre llegadas y el tiempo de servicio, validadas estadísticamente con la prueba de Kolmogorov-Smirnov, y un motor de simulación de eventos discretos. El modelo demostró un alto grado de validez: reprodujo, con diferencias menores al 1%, el comportamiento real observado tanto en el mes de menor demanda como en el de mayor demanda.

A partir del modelo validado, se evaluaron tres escenarios de demanda (optimista, normal y pesimista) y una propuesta de mejora (TO-BE) consistente en incorporar un quinto agente durante los periodos de alta demanda. Los resultados muestran que este único cambio agregar un agente permite recuperar el cumplimiento del estándar de servicio de 82.39% a 94.43% en el mes más exigente del año, y reduce el tiempo de espera promedio en 75.6%, con una implementación de baja complejidad operativa.

Se recomienda que la organización incorpore un quinto agente a partir de septiembre mes en que la demanda comienza a superar la capacidad instalada, monitoree mensualmente el cumplimiento del estándar de servicio, y reevalúe periódicamente el dimensionamiento del equipo, dado que la tendencia de crecimiento observada en 2021 podría continuar en periodos posteriores.

3. Introducción

La simulación de sistemas es una técnica que permite imitar el comportamiento de un sistema real mediante un modelo computacional, con el propósito de estudiar su funcionamiento, anticipar el efecto de distintas decisiones y evaluar alternativas de mejora sin necesidad de intervenir sobre la operación real. El presente trabajo aplica esta técnica al análisis de un centro de atención telefónica (call center), con el objetivo de comprender por qué su nivel de servicio se deterioró a lo largo de 2021 y de determinar, con evidencia cuantitativa, qué cambio operativo permitiría recuperarlo.

El trabajo integra, de manera aplicada, los principales conceptos desarrollados a lo largo del curso Simulación de Sistemas: la formulación de un modelo conceptual y su representación mediante notación BPMN; el análisis estadístico de datos y la selección de distribuciones de probabilidad, validada con la prueba de bondad de ajuste de Kolmogorov-Smirnov; la teoría de colas y la notación de Kendall; y la construcción de un modelo computacional de simulación de eventos discretos con Python, NumPy y SciPy.

A diferencia de un ejercicio académico típico, en el que los parámetros del modelo (tasas de llegada y de servicio) se entregan como datos del enunciado, este trabajo parte de un conjunto de datos reales: el registro completo de 51 708 llamadas atendidas por un call center de cuatro agentes durante el año 2021 (Bangs, 2021). Esta diferencia obliga a resolver un paso adicional estimar los parámetros del modelo a partir de los datos observados, pero permite, a cambio, validar el modelo resultante contra el comportamiento real del sistema, en lugar de basarse únicamente en supuestos teóricos.

El informe se organiza partiendo de la identificación y el planteamiento del problema, definiendo luego el modelo conceptual y su representación BPMN, analizando y preparando los datos, construyendo y validando el modelo computacional, presentando los resultados del escenario actual y de los escenarios alternativos, y formulando y sustentando una propuesta de mejora, antes de cerrar con las conclusiones y recomendaciones finales.

4. Planteamiento del problema

Los centros de atención telefónica (call centers) constituyen uno de los puntos de contacto más sensibles entre una organización y sus clientes, ya que la percepción de calidad del servicio depende en gran medida de la rapidez con la que una llamada es atendida. El presente trabajo analiza el caso de un call center que opera de lunes a viernes, de 8:00 a. m. a 6:00 p. m., y que cuenta con cuatro agentes de atención trabajando de forma simultánea durante toda la jornada (Bangs, 2021). La organización se ha fijado como estándar de servicio que el 90% de las llamadas recibidas sean contestadas en un plazo no mayor a 60 segundos, un indicador ampliamente utilizado en la gestión de centros de contacto para garantizar la satisfacción del cliente.

Durante el año 2021, el call center registró un total de 51 708 llamadas (Bangs, 2021). Al examinar la evolución mensual del cumplimiento de este estándar se observa un patrón de deterioro progresivo y sostenido: en enero, cuando el volumen de llamadas era de 3000 al mes, el 97.5% de las llamadas se atendían dentro del tiempo objetivo, con una espera promedio de apenas 5.4 segundos. Sin embargo, conforme la demanda fue creciendo mes a mes —hasta alcanzar 6249 llamadas en diciembre, es decir, más del doble del volumen inicial— el porcentaje de cumplimiento cayó de forma constante hasta ubicarse en 83.5% en el último mes del año, con un tiempo de espera promedio de 35.5 segundos, seis veces mayor que el registrado once meses antes.

Este comportamiento constituye el síntoma central del problema: la capacidad de atención del call center, fija en cuatro agentes durante todo el año, no fue ajustada frente a un crecimiento sostenido de la demanda. Como consecuencia, un número creciente de clientes debió esperar más tiempo del tolerado por el estándar de servicio, lo cual representa un riesgo directo sobre la satisfacción del cliente, la percepción de calidad del servicio y, potencialmente, la retención de usuarios. La causa probable de este deterioro no es evidente a simple vista: podría deberse a un aumento genuino de la demanda, a cambios en la duración promedio de las llamadas, a una combinación de ambos factores, o a la interacción no lineal entre la variabilidad de las llegadas y la capacidad fija del sistema, típica de los sistemas de colas.

Precisamente por esta razón, el problema no puede resolverse mediante un cálculo determinístico simple. Un sistema de colas con llegadas y tiempos de servicio aleatorios —como el que aquí se describe— presenta un comportamiento no lineal en el que pequeños incrementos en la tasa de llegada pueden producir aumentos desproporcionados en el tiempo de espera cuando la utilización del sistema se aproxima a su capacidad máxima (Taha, 2017). Esta es exactamente la clase de problema para la cual la simulación de sistemas resulta una herramienta más adecuada que el análisis puramente analítico: permite reproducir el comportamiento del sistema bajo distintos niveles de demanda, cuantificar el impacto de cada escenario sobre los indicadores de servicio, y evaluar de manera anticipada —sin intervenir sobre la operación real— cuántos agentes adicionales serían necesarios para que el call center recupere el cumplimiento del estándar de 90%, incluso bajo el nivel de demanda observado en los meses de mayor carga.

5. Objetivos

5.1. Objetivo general

Diseñar, implementar y validar un modelo de simulación de eventos discretos que permita analizar la capacidad de atención del call center estudiado y determinar el número de agentes necesario para restablecer el cumplimiento del estándar de servicio (90% de las llamadas atendidas en 60 segundos o menos) bajo distintos niveles de demanda, sustentando una propuesta de mejora con base en evidencia cuantitativa.

5.2. Objetivos específicos

1. Formular el modelo conceptual del sistema de atención telefónica, identificando entidades, recursos, eventos, colas y variables de entrada, estado y salida.
2. Modelar el proceso actual (AS-IS) de atención de llamadas mediante un diagrama BPMN, identificando los puntos de espera y el posible cuello de botella.
3. Analizar estadísticamente los datos reales de las 51 708 llamadas registradas durante el año 2021, calculando indicadores descriptivos del tiempo entre llegadas y del tiempo de servicio.

4. Ajustar y justificar las distribuciones de probabilidad que mejor representan el tiempo entre llegadas y el tiempo de servicio de las llamadas.
5. Construir un modelo computacional de simulación de eventos discretos con Python, NumPy y SciPy que reproduzca el comportamiento del sistema bajo la configuración actual de cuatro agentes.
6. Ejecutar réplicas de la simulación para el escenario AS-IS y validar el modelo comparando los indicadores simulados contra los valores observados en los datos reales.
7. Diseñar y comparar escenarios alternativos (optimista, normal y pesimista) variando el número de agentes disponibles, para determinar la configuración mínima que restablece el cumplimiento del estándar de servicio.
8. Proponer un rediseño TO-BE del proceso de atención, sustentado en los resultados cuantitativos obtenidos mediante la simulación.

5.3. Alcance del modelo

El modelo comprende el proceso de recepción, espera y atención de llamadas entrantes durante el horario de operación del call center (8:00 a. m. a 6:00 p. m., de lunes a viernes). Las variables modeladas son el tiempo entre llegadas de llamadas, el tiempo de servicio por llamada y el número de agentes disponibles para atender.

5.4. Exclusiones

- No se modela el contenido ni el motivo de las llamadas, ya que el dataset no registra esa información.
- No se consideran llamadas fuera del horario laboral establecido.
- No se modela explícitamente el abandono de llamadas (reneging), salvo los casos aislados de duración de servicio igual a cero identificados en el análisis de datos.
- No se incluye un análisis de costos salariales reales de los agentes; de requerirse el indicador de costo operativo, se trabajará con un supuesto referencial documentado.

5.5. Restricciones

- El modelo se basa en datos históricos de un año (2021) de un call center simulado publicado públicamente en Kaggle (Bangs, 2021), por lo que los resultados son

representativos del comportamiento de ese sistema y no de un caso verificado en campo.

- El número de agentes de la configuración AS-IS (cuatro) se toma de la documentación oficial del dataset, dado que esta variable no está registrada explícitamente en cada llamada.

5.6. Criterios de éxito

- Restablecer el cumplimiento del estándar de servicio ($\geq 90\%$ de llamadas atendidas en ≤ 60 segundos) bajo el nivel de demanda observado en el mes de mayor carga (diciembre, 6249 llamadas).
- Reducir el tiempo de espera promedio en al menos 50% respecto al escenario AS-IS de diciembre (35.5 segundos).
- Mantener la utilización de los agentes en un rango razonable (idealmente entre 70% y 85%) en la propuesta TO-BE, evitando el sobredimensionamiento de recursos.
- Identificar el número mínimo de agentes adicionales necesario para cumplir los puntos anteriores, como base para una recomendación costo-efectiva.

6. Alcance y frontera del sistema

6.1. Elementos incluidos

- El proceso completo de atención de una llamada: llegada, registro, verificación de disponibilidad, espera en cola (de ser necesaria), atención, resolución y cierre.
- El cálculo de los indicadores de tiempo de espera (`wait_length`), tiempo de servicio (`service_length`) y cumplimiento del estándar de servicio (`meets_standard`).
- La simulación de la capacidad de atención bajo distintos números de agentes (configuración AS-IS de 4 agentes y configuraciones alternativas TO-BE).

6.2. Elementos excluidos

- El motivo o contenido de la llamada (el dataset no registra esta información).
- Las llamadas realizadas fuera del horario de atención (8:00 a. m.-6:00 p. m., lunes a viernes).

- El abandono de llamadas como evento explícito y modelado con su propia distribución; solo se documentan los casos aislados de duración de servicio igual a cero identificados en el análisis de datos.
- Los costos salariales reales de los agentes; de emplearse un indicador de costo, se hará sobre un supuesto referencial documentado.
- Otros canales de atención (correo, chat, redes sociales), dado que el dataset solo contiene llamadas telefónicas.

6.3. Interacciones con el entorno

El sistema recibe llamadas generadas por clientes externos a la organización; este proceso de llegada se trata como un insumo externo al modelo, caracterizado estadísticamente a partir de los datos históricos, y no como un subproceso a simular en detalle. El modelo no interactúa con otros sistemas internos de la organización (CRM, facturación, gestión de tickets, etc.), ya que el dataset utilizado no registra ese tipo de información.

6.4. Justificación de los límites

El análisis se limita a la operación de atención telefónica porque es el proceso para el cual se dispone de datos reales, granulares (a nivel de cada una de las 51 708 llamadas) y confiables, con lo cual es posible construir y validar un modelo de simulación con evidencia cuantitativa. Ampliar el alcance a otros procesos de la organización excedería la información disponible y se alejaría del propósito central del trabajo: analizar y proponer mejoras sobre la capacidad de atención (número de agentes) frente al crecimiento sostenido de la demanda observado durante el año 2021.

7. Descripción del proceso seleccionado

A continuación se describe de manera sintética el sistema seleccionado para el presente trabajo.

Elemento	Descripción
Nombre del proceso	Atención de llamadas entrantes en un centro de atención telefónica (call center).
Organización o contexto	Call center que brinda atención a clientes en horario de 8:00 a. m. a 6:00 p. m., de lunes a viernes. Los datos corresponden a un dataset público de simulación (Bangs, 2021), utilizado en este trabajo como fuente de datos reales de entrada.
Usuarios o clientes	Personas que llaman solicitando ser atendidas por un agente del call center.
Recursos involucrados	Cuatro (4) agentes de atención, disponibles de forma simultánea durante toda la jornada laboral.
Entradas	Llamadas entrantes, caracterizadas por su instante de llegada (tiempo entre llegadas).
Salidas	Llamadas atendidas y finalizadas, con su tiempo de espera en cola y su tiempo de servicio registrados.
Problema principal	Deterioro progresivo del cumplimiento del estándar de servicio (90% de llamadas atendidas en 60 segundos o menos) a lo largo del año 2021, como consecuencia del crecimiento sostenido de la demanda frente a una capacidad de atención fija.
Restricciones del sistema	Capacidad fija de 4 agentes durante todo el periodo analizado; horario de atención fijo (8:00 a. m.-6:00 p. m., lunes a viernes); el dataset no identifica al agente que atendió cada llamada de forma individual.

8. Modelo conceptual

El modelo conceptual formaliza los elementos del sistema de atención telefónica descrito en la sección anterior.

Elemento	Descripción aplicada al caso
Entidades	Llamadas telefónicas entrantes.
Recursos	Agentes de atención (4 disponibles de forma simultánea durante toda la jornada).
Eventos	Llegada de la llamada, inicio de atención (asignación a un agente disponible), fin de atención (cierre de la llamada), salida del sistema.
Colas	Cola de llamadas en espera de ser atendidas por un agente disponible.
Variables de entrada	Tiempo entre llegadas de llamadas (derivado de los timestamps de llegada), tiempo de servicio por llamada, número de agentes disponibles.
Variables de estado	Número de llamadas en espera; número de agentes ocupados en un instante dado.
Variables de salida	Tiempo de espera en cola, tiempo total en el sistema, porcentaje de llamadas que cumplen el estándar de servicio (≤ 60 segundos), utilización de los agentes.
Supuestos	Los tiempos entre llegadas siguen una distribución Exponencial (a validar en la sección de análisis estadístico); las llamadas se atienden en orden de llegada (disciplina FIFO); los cuatro agentes tienen la misma capacidad de atención; no se modela el abandono de llamadas salvo los casos de duración de servicio igual a cero.
Frontera	Se incluye el proceso desde la llegada de la llamada hasta su finalización dentro del horario de atención (8:00 a. m.-6:00 p. m., lunes a viernes). Se excluyen llamadas fuera de ese horario, el contenido/motivo de la llamada y los procesos administrativos internos del call center ajenos a la atención telefónica.
Indicadores de desempeño	Tiempo promedio de espera, tiempo promedio en el sistema, porcentaje de cumplimiento del SLA (90% en ≤ 60 s), utilización de agentes, throughput (llamadas atendidas por hora).

9. Diagrama BPMN AS-IS

El proceso actual (AS-IS) de atención de llamadas se modeló en notación BPMN 2.0 (eventos, actividades, compuertas, carriles). El diagrama fue construido como un archivo BPMN 2.0 estándar (diagramas/bpmn_as_is.bpmn) e importado en Bizagi Modeler para su edición y exportación gráfica.

9.1. Actores (carriles) del proceso

Actor (carril)	Rol en el proceso
Cliente	Inicia la llamada y recibe la atención final.
Sistema / Central Telefónica	Registra la llamada, verifica disponibilidad, gestiona la cola y calcula los indicadores.
Agente de Atención	Atiende, resuelve y cierra la llamada (uno de los cuatro agentes disponibles).

9.2. Fases del proceso

#	Fase	Actor	Elemento BPMN
1	Llegada de la llamada	Cliente	Evento de inicio
2	Registro de la llamada (timestamp de llegada)	Sistema	Tarea
3	Verificación de disponibilidad (¿hay agente libre de los 4?)	Sistema	Compuerta exclusiva
4	Cola de espera FIFO cuello de botella identificado	Sistema	Tarea
5	Atención de la llamada por el agente disponible	Agente	Tarea
6	Resolución de la consulta (tiempo de servicio)	Agente	Tarea
7	Cierre de la llamada (timestamp de fin)	Agente	Tarea
8	Cálculo de indicadores (espera, servicio)	Sistema	Tarea
9	Verificación de cumplimiento del SLA (¿espera $\leq$ 60 s?)	Sistema	Compuerta exclusiva
10	Registro de cumplimiento o incumplimiento del estándar	Sistema	Tarea
11	Fin de la llamada	Cliente	Evento de fin

9.3. Diagrama




Diagrama BPMN del proceso AS-IS de atención de llamadas (3 carriles: Cliente, Sistema/Central Telefónica, Agente de Atención).

El punto crítico señalado explícitamente en el diagrama es la tarea “Llamada ingresa a la cola de espera (FIFO) — cuello de botella”, que es la representación gráfica del problema : cuando los cuatro agentes están ocupados, las llamadas entrantes se acumulan en espera, generando los tiempos prolongados que explican la caída del cumplimiento del SLA observada en los meses de mayor demanda.

10. Datos utilizados

10.1. Fuente de los datos

Los datos utilizados en este trabajo provienen del conjunto de datos público “Call Centre Queue Simulation” (Bangs, 2021), disponible en la plataforma Kaggle. Se trata de un registro simulado, pero estadísticamente realista, del funcionamiento de un call center durante el año 2021, generado originalmente con el paquete *simmer* de R para simulación de eventos discretos (Ucar et al., 2019, como se citó en Bangs, 2021). Para efectos de este trabajo, los datos se tratan como la fuente de información real de entrada, dado que el examen final permite el uso de datos simulados cuando no se dispone de datos reales de campo, siempre que se documenten y justifiquen adecuadamente.

El archivo original (simulated_call_centre.csv) fue procesado para traducir el nombre de sus columnas al español, con el fin de facilitar su lectura e interpretación a lo largo del presente informe. El archivo resultante, SimulacionCallCenter.csv, es el que se utiliza en el resto del trabajo.

10.2. Estructura del dataset

El dataset contiene 51 708 registros, cada uno correspondiente a una llamada individual recibida entre el 1 de enero y el 31 de diciembre de 2021, en días hábiles (lunes a viernes), dentro del horario de atención de 8:00 a. m. a 6:00 p. m. Las columnas del dataset traducido son las siguientes:

Columna	Descripción
id_llamada	Identificador único de cada llamada.
fecha	Fecha en que se recibió la llamada.
numero_llamada_del_dia	Orden de la llamada dentro del día (1. ^a , 2. ^a , 3. ^a llamada del día, etc.).
hora_inicio_llamada	Hora en que el cliente marcó / la llamada ingresó al sistema.
hora_contestada	Hora en que un agente tomó la llamada.
hora_finalizada	Hora en que la llamada terminó (fue resuelta).
tiempo_espera_seg	Tiempo que el cliente esperó en cola antes de ser atendido, en segundos.
tiempo_servicio_seg	Tiempo que el agente empleó atendiendo la llamada, en segundos.
cumple_estandar	Indica si la llamada fue contestada en 60 segundos o menos (“Si”/“No”).

10.3. Preparación de datos derivados

El dataset no incluye directamente el tiempo entre llegadas de llamadas consecutivas, variable indispensable para caracterizar el proceso de arribo en un modelo de colas. Este valor se derivó combinando la fecha y la hora de inicio de cada llamada en una marca de tiempo completa, y calculando la diferencia respecto a la llamada inmediatamente anterior dentro del mismo día. La primera llamada de cada día no genera un tiempo entre llegadas (no existe llamada previa ese día), por lo que dicho valor se descarta del análisis estadístico.

10.4. Verificación de calidad de los datos

Antes de utilizar los datos se realizó una verificación de calidad: no se encontraron valores nulos ni identificadores de llamada duplicados; el orden temporal de los eventos (inicio, contestada, finalizada) es correcto en el 100% de los registros; y las pequeñas diferencias (± 1 segundo) encontradas al recalcular los tiempos de espera y de servicio a partir de las marcas de tiempo corresponden a redondeo y no representan errores reales de los datos. Se identificaron 88 llamadas con tiempo de servicio igual a cero, que se documentan como posibles llamadas caídas o abandonadas inmediatamente después de ser contestadas, y se tratan como un caso particular a considerar en el análisis, sin excluirlas del conjunto de datos.

11. Análisis estadístico de datos

11.1. Estadística descriptiva general

Sobre el total de 51 708 llamadas registradas durante el año 2021, se calcularon los principales indicadores descriptivos del tiempo de espera en cola, el tiempo de servicio y el tiempo entre llegadas de llamadas consecutivas (esta última variable, derivada a partir de las marcas de tiempo de llegada de cada llamada). Los resultados se resumen en la Tabla siguiente.

Variable	Media	Mediana	Desv. estándar	Máximo
Tiempo de espera (seg)	17.03	0.00	64.06	983
Tiempo de servicio (seg)	299.10	208.00	299.87	3110
Tiempo entre llegadas (seg)	180.58	122.00	188.05	2718

El tiempo de espera presenta una mediana de 0 segundos, lo que indica que en más de la mitad de las llamadas el cliente fue atendido de inmediato; sin embargo, la desviación estándar (64.06) es considerablemente mayor que la media (17.03), lo que revela una fuerte asimetría hacia la derecha: existe un subconjunto de llamadas con esperas muy prolongadas (hasta 983 segundos, es decir, algo más de 16 minutos) que eleva el promedio general. Un patrón similar, aunque menos extremo, se observa en el tiempo de servicio, cuya media

(299.10 s) y desviación estándar (299.87 s) son prácticamente iguales, lo cual es característico de una distribución con cola larga hacia la derecha.

Para completar el requisito de la Actividad 6, se calcularon además el valor mínimo y los percentiles 90, 95 y 99 de cada variable (Tabla siguiente). El mínimo de 0 en las tres variables es consistente con la naturaleza de los datos: una espera de 0 segundos ocurre cuando un agente está libre al momento de la llamada, un servicio de 0 segundos corresponde a llamadas que se cortan apenas contestadas, y un tiempo entre llegadas de 0 ocurre cuando dos llamadas quedan registradas en el mismo segundo, dada la resolución del timestamp.

Variable	Mínimo	Percentil 90	Percentil 95	Percentil 99
Tiempo de espera (seg)	0	32	129	347
Tiempo de servicio (seg)	0	688	889	1390
Tiempo entre llegadas (seg)	0	418	553	874

El percentil 90 del tiempo de espera (32 segundos) está por debajo del límite de 60 segundos que exige el estándar de servicio, lo cual, a nivel de todo el año, sugiere un cumplimiento aceptable; sin embargo, esta cifra agregada oculta el deterioro progresivo documentado más adelante. Los percentiles del tiempo entre llegadas (418 s en el percentil 90) resultan clave para la estimación de la tasa de llegada λ del modelo computacional, a partir de la media de esta variable.




Figura 1. Distribución del tiempo de espera en cola.




Figura 2. Distribución del tiempo de servicio.

Como complemento gráfico requerido por la Actividad 6, se construyeron también los diagramas de caja (boxplot) de ambas variables (Figuras 3 y 4). El boxplot del tiempo de espera aparece visualmente inusual —la caja colapsa en una línea sobre el cero y casi todos los valores mayores a cero se marcan como atípicos—, lo cual es consecuencia

directa de que los percentiles 25, 50 y 75 de esta variable son 0, no un error de graficación.




Figura 3. Diagrama de caja del tiempo de espera en cola.




Figura 4. Diagrama de caja del tiempo de servicio.

11.2. Evolución mensual del cumplimiento del SLA

El hallazgo más relevante del análisis estadístico es la evolución mensual del cumplimiento del estándar de servicio (90% de llamadas atendidas en 60 segundos o menos). Como se observa en la Tabla siguiente, el volumen de llamadas se duplicó entre enero (3000 llamadas) y diciembre (6249 llamadas) de 2021, mientras que la capacidad de atención se mantuvo fija en cuatro agentes durante todo el año. Como consecuencia, el

porcentaje de llamadas atendidas dentro del estándar cayó de 97.47% en enero a 83.45% en diciembre, y el tiempo de espera promedio se multiplicó por más de seis veces (de 5.38 a 35.54 segundos).

Mes (2021)	Llamadas	% cumple SLA	Espera prom. (seg)
Enero	3000	97.47%	5.38
Febrero	3061	97.52%	4.36
Marzo	3613	97.23%	5.66
Abril	3642	97.17%	4.79
Mayo	3619	95.77%	7.98
Junio	4012	95.01%	9.22
Julio	4340	93.96%	11.79
Agosto	4563	92.09%	16.16
Septiembre	5022	89.88%	21.54
Octubre	4988	88.23%	27.89
Noviembre	5599	86.30%	27.37
Diciembre	6249	83.45%	35.54




Figura 5. Volumen mensual de llamadas y porcentaje de cumplimiento del SLA (2021).

A partir de septiembre de 2021, el porcentaje de cumplimiento cae por debajo del objetivo del 90%, y la tendencia se mantiene negativa hasta el cierre del año. Este comportamiento confirma, con evidencia cuantitativa, el planteamiento del problema: el crecimiento sostenido de la demanda no fue acompañado por un ajuste en la capacidad de atención.

11.3. Nota sobre calidad de los datos

Los datos no presentan valores nulos, duplicados ni inconsistencias temporales, por lo que el análisis estadístico presentado en esta sección se realizó sobre el conjunto completo de 51 708 registros, sin necesidad de excluir observaciones adicionales.

12. Distribuciones seleccionadas

Se evaluó si el tiempo entre llegadas y el tiempo de servicio del call center se ajustan a una distribución Exponencial, mediante `scipy.stats`. La justificación se realizó en dos niveles: un criterio estadístico descriptivo (comparación entre la media y la desviación estándar) y una prueba formal de bondad de ajuste de Kolmogorov-Smirnov (`scipy.stats.kstest`).

12.1. Criterio descriptivo: media frente a desviación estándar

Una propiedad conocida de la distribución Exponencial es que su media y su desviación estándar teóricas son iguales. Al comparar ambos valores en los datos reales, se observa una coincidencia notable en las dos variables analizadas:

Variable	Media (seg)	Desv. estándar (seg)	Relación
Tiempo entre llegadas	180.58	188.05	Muy cercanas
Tiempo de servicio	299.10	299.87	Prácticamente iguales

Esta cercanía entre media y desviación estándar es la primera evidencia, a nivel descriptivo, de que ambas variables podrían modelarse mediante una distribución Exponencial.

12.2. Prueba de bondad de ajuste (Kolmogorov-Smirnov)

Se aplicó la prueba de Kolmogorov-Smirnov (H_0 : los datos provienen de una distribución Exponencial con el parámetro estimado a partir de la media muestral) sobre ambas variables, con un nivel de significancia $\alpha = 0.05$. Los resultados fueron los siguientes:

Variable	Estadístico D	p-valor	Conclusión ($\alpha=0.05$)
Tiempo de servicio	0.0029	0.7734	No se rechaza H0
Tiempo entre llegadas	0.0119	0.0000	Se rechaza H0 (formalmente)

Para el tiempo de servicio, la prueba no rechaza la hipótesis de que los datos provienen de una distribución Exponencial ($p = 0.7734$), por lo que se adopta esta distribución sin reservas.

Para el tiempo entre llegadas, la prueba rechaza formalmente la hipótesis nula ($p \approx 0.000$). Sin embargo, este resultado debe interpretarse con cuidado: el estadístico D obtenido (0.0119) es muy pequeño —indica una distancia máxima de apenas 1.19% entre la distribución empírica y la teórica—, y con un tamaño de muestra tan grande ($n = 51\,447$) la prueba de Kolmogorov-Smirnov adquiere una potencia estadística muy alta, capaz de detectar y rechazar formalmente incluso desviaciones mínimas que carecen de relevancia práctica. Esta es una limitación conocida de las pruebas de bondad de ajuste en muestras grandes. Dado que (a) el estadístico D es pequeño, (b) la media y la desviación estándar son casi idénticas, y (c) la distribución Exponencial es el modelo estándar para el tiempo entre llegadas en un proceso de arribos tipo Poisson, se adopta la distribución Exponencial también para el tiempo entre llegadas, como una aproximación adecuada para fines de simulación.




Figura 6. Histograma de los datos reales frente a la densidad Exponencial ajustada.

12.3. Distribuciones finales adoptadas

Variable	Distribución	Parámetro (<code>scipy.stats.expon</code>)
Tiempo entre llegadas	Exponencial	scale = 180.58 s ($\lambda \approx 1/180.58$ por segundo)
Tiempo de servicio	Exponencial	scale = 299.10 s ($\mu \approx 1/299.10$ por segundo)

Con ambas variables modeladas mediante distribuciones Exponenciales, el sistema corresponde a un modelo de colas M/M/c en notación de Kendall (llegadas markovianas, servicio markoviano, $c = 4$ servidores), lo cual permite aplicar tanto la simulación manual de eventos discretos como las fórmulas teóricas de teoría de colas, empleadas más adelante.

13. Modelo computacional

13.1. Enfoque y herramientas

El modelo computacional se construyó en Python, utilizando NumPy y SciPy para la generación de variables aleatorias, y un motor de simulación de eventos discretos con múltiples servidores. No se empleó ninguna librería de simulación externa (por ejemplo, SimPy).

El motor de simulación asigna cada llamada entrante al agente que quede libre primero —de los cuatro disponibles—, utilizando la función `np.argmin()` sobre un arreglo que registra el instante en que cada agente vuelve a estar disponible. El inicio de cada atención se calcula como el máximo entre el instante de llegada de la llamada y el instante en que el agente asignado queda libre, generalizando la lógica de una cola de un solo servidor a un sistema con múltiples servidores en paralelo.

13.2. Parámetros del modelo AS-IS

El escenario AS-IS se calibró con la demanda del mes de diciembre de 2021 —el mes de mayor carga y peor cumplimiento del SLA— y con la configuración real de cuatro agentes documentada por la fuente del dataset.

Parámetro	Valor
Número de agentes (c)	4
Tasa de servicio (μ)	1 / 299.10 s $\approx$ 0.00334 llamadas/seg
Tasa de llegada de diciembre (λ)	1 / 132.50 s $\approx$ 0.00755 llamadas/seg (6 249 llamadas en 23 días hábiles, 10 h/día)
Llamadas simuladas por corrida	6 249 (igual al volumen real de diciembre)
Estándar de servicio (SLA)	espera $\leq$ 60 segundos
Semilla base	42 (Laboratorio N.º 1), con variación por réplica

13.3. Resultado de una corrida de demostración

Como primera verificación de que el modelo se comporta de forma razonable, se ejecutó una corrida individual (semilla = 42) y se comparó contra los valores reales observados en diciembre de 2021. La cercanía de ambos resultados es la primera señal de que el modelo representa adecuadamente el sistema real; la validación formal se desarrolla más adelante.

Indicador	Simulado (semilla 42)	Real (diciembre 2021)
Tiempo de espera promedio	35.79 s	35.54 s
% de llamadas que cumplen el SLA	84.09%	83.45%
Utilización de agentes (teórica / simulada)	56.43% / 55.90%	56.37%

La utilización real se calculó restringiendo el cálculo al horario efectivo de atención (8:00 a. m. a 6:00 p. m., 23 días hábiles de diciembre): tiempo de servicio total acumulado, dividido entre la capacidad disponible (23 días $\times$ 10 horas $\times$ 4 agentes). El resultado (56.37%) es prácticamente idéntico a la utilización teórica y simulada, lo que confirma que el modelo reproduce correctamente no solo los tiempos de espera, sino también el nivel de carga de trabajo de los agentes.

13.4. Ejecución de réplicas

Dado que el sistema presenta alta variabilidad (coeficiente de variación cercano a 1 tanto en llegadas como en servicio, según lo analizado previamente), se ejecutaron 30 réplicas del escenario AS-IS, cada una con una semilla distinta, siguiendo la recomendación del propio examen final para modelos con mayor variabilidad. Los

resultados agregados de las 30 réplicas se presentan en la Tabla siguiente y se retoman con mayor detalle más adelante.

Indicador (30 réplicas)	Media	Desv. estándar	Rango (mín-máx)
Tiempo de espera promedio (seg)	42.36	6.24	32.15 - 59.16
% cumple SLA	82.85%	1.42%	80.08% - 85.69%
Utilización simulada	56.3%	1.1%	54.4% - 59.6%

El valor real observado en diciembre de 2021 (espera promedio de 35.54 s, 83.45% de cumplimiento) se encuentra dentro —o muy próximo a— del rango generado por las 30 réplicas del modelo, lo cual constituye evidencia de que el modelo reproduce de forma consistente el comportamiento real del sistema bajo el escenario AS-IS.

14. Verificación y validación del modelo

Siguiendo la estructura solicitada en la Actividad 11 del examen final, se documentan a continuación cuatro evidencias de revisión del modelo: verificación lógica, validación conceptual, validación con datos y revisión de supuestos.

Tipo de revisión	Evidencia
Verificación lógica	El modelo se ejecutó sin errores de flujo en la corrida de demostración y en las 30 réplicas (sección 13.4). Como control interno de consistencia, se comparó la utilización teórica ($\rho = \lambda / (c \cdot \mu) = 56.43\%$) contra la utilización efectivamente simulada (55.90%); la cercanía entre ambos valores confirma que la lógica de asignación de agentes (np.argmax) y el cálculo de tiempos de espera y servicio están correctamente implementados.
Validación conceptual	El modelo conceptual (sección 8) y el diagrama BPMN AS-IS (sección 9) se contrastaron contra la descripción del proceso real (sección 7): un call center con cuatro agentes que atienden llamadas en orden de llegada (FIFO), con un estándar de servicio de 60 segundos. No se identificaron elementos del proceso real que no estén representados en el modelo,

	dentro del alcance definido en la sección 6.
Validación con datos	Esta es la validación más sólida del trabajo: la corrida de demostración del modelo reproduce con alta fidelidad los indicadores reales de diciembre de 2021 (espera promedio simulada 35.79 s frente a 35.54 s real, una diferencia de apenas 0.7%; cumplimiento del SLA simulado 84.09% frente a 83.45% real). Adicionalmente, el valor real observado se encuentra dentro del rango generado por las 30 réplicas del modelo (espera promedio entre 32.15 s y 59.16 s), lo que confirma que el comportamiento real del sistema es consistente con lo que el modelo predice, y no un caso atípico fuera de su capacidad de representación.
Validación con experto	Al tratarse de un trabajo académico basado en un dataset público, no se contó con acceso directo a un supervisor real del call center. En su lugar, los parámetros centrales del modelo (cuatro agentes, tiempo de servicio promedio de 5 minutos, estándar de servicio de 90% en 60 segundos) fueron contrastados contra la documentación oficial y pública de la fuente de datos (Bangs, 2021), la cual actúa como una fuente autorizada equivalente a un experto del proceso. Se recomienda que, de extenderse este trabajo a un caso con acceso a información de campo, se valide adicionalmente con un responsable real de la operación.
Revisión de supuestos	Los supuestos y limitaciones del modelo, documentados a lo largo del informe (secciones 5.5, 6.2 y 8), se resumen en la sección 14.1.

14.1. Resumen de supuestos y limitaciones

- El tiempo entre llegadas y el tiempo de servicio siguen una distribución Exponencial (validado previamente, con la salvedad estadística explicada para el tiempo entre llegadas).

- Los cuatro agentes son homogéneos: cualquiera de ellos atiende con la misma distribución de tiempo de servicio.
- La disciplina de atención es FIFO (primero en llegar, primero en ser atendido).
- No se modela el abandono de llamadas como evento explícito con su propia distribución.
- El parámetro de servicio (μ) se asume constante a lo largo del año; no se modelan variaciones estacionales en la duración de las llamadas, solo en su frecuencia de llegada.
- La configuración de cuatro agentes se asume constante durante todo el mes de diciembre, sin turnos ni refuerzos puntuales.

14.2. Verificación lógica

La verificación lógica responde a la pregunta “¿el modelo se construyó correctamente?”, es decir, si el código implementa sin errores la lógica que se pretendía programar, independientemente de si esa lógica representa bien o no a la realidad. Se reunieron tres evidencias de verificación lógica:

- Comportamiento esperado en baja carga: al inspeccionar las primeras llamadas simuladas de una corrida individual, con los cuatro agentes libres desde el inicio y llegadas separadas por decenas o cientos de segundos, el modelo asigna atención inmediata (espera = 0) a cada una de ellas, tal como debería ocurrir cuando la demanda es baja respecto a la capacidad disponible.
- Consistencia entre utilización teórica y simulada: la fórmula $\rho = \lambda / (c \cdot \mu)$ predice una utilización teórica de 56.71% para diciembre con cuatro agentes; la utilización medida directamente sobre la corrida simulada (tiempo de servicio acumulado entre capacidad total) fue de 56.17%. La cercanía entre ambos valores confirma que la contabilidad interna del modelo (registro de tiempos de inicio, fin y ocupación de cada agente) es consistente con la fórmula teórica que debería cumplir.
- Condición de estabilidad: se verificó que $\lambda < c \cdot \mu$ ($0.007584 < 4 \times 0.003343 = 0.013373$ llamadas/segundo) para el escenario AS-IS, condición necesaria para que el sistema sea estable y no acumule una cola creciente sin límite, condición estándar de estabilidad en un sistema de colas M/M/c.

14.3. Validación conceptual

La validación conceptual evalúa si la estructura del modelo —no sus resultados numéricos— representa adecuadamente el proceso real descrito en el modelo conceptual y en el diagrama BPMN AS-IS. Se identifican las siguientes correspondencias:

- Los cuatro agentes del modelo computacional corresponden exactamente a los cuatro recursos identificados en el modelo conceptual y a los cuatro carriles de “Agente” considerados en el BPMN AS-IS.
- La disciplina de atención FIFO programada en el bucle de asignación (el agente que se libera primero atiende la siguiente llamada en espera) coincide con el flujo secuencial de atención descrito en el BPMN, sin bifurcaciones de prioridad.
- La notación de Kendall M/M/c adoptada es conceptualmente coherente con los eventos identificados en el modelo conceptual: llegada, inicio de atención y fin de atención, sin eventos adicionales no contemplados en el proceso real.

14.4. Validación con datos

La validación con datos es la evidencia central de esta sección: compara las salidas del modelo contra el comportamiento real observado, siguiendo la definición estándar de validación (“¿se construyó el modelo correcto?”). Se documentan cuatro niveles de evidencia, de menor a mayor rigurosidad estadística.

Primer nivel — corrida individual: una corrida de demostración (semilla = 42) sobre la demanda de diciembre arrojó una espera promedio de 36.45 s y un 83.85% de cumplimiento del SLA, frente a los valores reales de diciembre de 2021 (35.54 s y 83.45%, respectivamente).

Segundo nivel — 30 réplicas: el valor real de cumplimiento (83.45%) se ubica dentro del rango generado por 30 réplicas independientes del modelo (79.77% a 85.52%), como se ilustra en la Figura 7.

Tercer nivel — validación en los doce meses del año: para reforzar la validación más allá del mes de diciembre, se estimó la tasa de llegada λ de cada uno de los doce meses de 2021 con el mismo procedimiento (media de los tiempos entre llegadas reales de ese mes)

y se simuló cada mes con la configuración AS-IS de cuatro agentes. La Tabla siguiente compara el porcentaje de cumplimiento del SLA simulado contra el real, mes a mes.

Mes	% cumple real	% cumple simulado	Diferencia
Enero	97.47	97.59	+0.12
Febrero	97.52	97.23	-0.28
Marzo	97.23	97.10	-0.14
Abril	97.17	96.39	-0.79
Mayo	95.77	96.03	+0.26
Junio	95.01	95.05	+0.03
Julio	93.96	93.52	-0.44
Agosto	92.09	92.45	+0.36
Septiembre	89.88	90.06	+0.17
Octubre	88.23	88.11	-0.12
Noviembre	86.30	85.52	-0.78
Diciembre	83.45	82.55	-0.90

En los doce meses, la diferencia entre el porcentaje simulado y el real nunca supera 1 punto porcentual, tanto en los meses de baja demanda (enero, con 97%+ de cumplimiento) como en los de alta demanda (diciembre, con 83%). Esto confirma que el motor de simulación reproduce el comportamiento real del sistema bajo distintos niveles de carga, y no solo en el escenario más exigente elegido para el análisis AS-IS/TO-BE.

Cuarto nivel — prueba de hipótesis formal: se aplicó la prueba de Kolmogorov-Smirnov de dos muestras (`scipy.stats.ks_2samp`), que compara si dos conjuntos de datos provienen de la misma distribución de probabilidad, sobre las esperas simuladas de la corrida de demostración frente a las esperas reales de diciembre. El resultado fue un estadístico $D = 0.0086$ y un $p\text{-valor} = 0.9738$; al no rechazarse la hipótesis nula ($\alpha = 0.05$), no hay evidencia estadística de que la distribución simulada difiera de la real. Esta prueba es la misma familia utilizada previamente para la selección de distribuciones (`kstest` de una muestra contra una fórmula teórica), aplicada aquí a dos muestras de datos entre sí.

15. Resultados del escenario AS-IS

Esta sección presenta los resultados agregados de las 30 réplicas del escenario AS-IS (cuatro agentes, demanda de diciembre de 2021), e interpreta lo que estos resultados significan como línea base de comparación para los escenarios que se analizan a continuación.

Indicador	Media	Desv. estándar	Mínimo	Máximo
Tiempo de espera promedio (seg)	42.36	6.24	32.15	59.16
% de llamadas que cumplen el SLA	82.85%	1.42%	80.08%	85.69%
Utilización de agentes (simulada)	56.3%	1.1%	54.4%	59.6%
Tiempo de servicio promedio (seg)	298.82	4.13	291.12	309.75

Escenario AS-IS (4 agentes, demanda de diciembre) - 30 réplicas




Figura 7. Distribución de la espera promedio y del % de cumplimiento del SLA en las 30 réplicas del escenario AS-IS, comparadas contra el valor real observado en diciembre de 2021.

El valor real observado en diciembre de 2021 (espera promedio de 35.54 segundos, 83.45% de cumplimiento del SLA) se ubica dentro del rango generado por las 30 réplicas del modelo, y específicamente dentro de una desviación estándar de la media simulada en 14 de las 30 réplicas. Esto confirma que el comportamiento real observado no es un caso

atípico, sino un resultado plausible dentro de la variabilidad natural que el propio modelo predice para este nivel de demanda.

El resultado central de esta sección es que, bajo la configuración actual de cuatro agentes y el volumen de llamadas observado en el mes de mayor carga, el call center opera de forma sostenida por debajo del estándar de servicio del 90%: en ninguna de las 30 réplicas se alcanzó dicho objetivo (el máximo obtenido fue 85.69%, y la media se ubica en 82.85%). La utilización de los agentes, en promedio 56.3%, no es particularmente alta en términos absolutos; sin embargo, dado que las llegadas y los tiempos de servicio son altamente variables (coeficiente de variación cercano a 1, según lo analizado previamente), esa utilización moderada es suficiente para generar colas y esperas significativas en los momentos de mayor concentración de llamadas. Este resultado confirma, con evidencia de simulación, el problema planteado inicialmente, y constituye la línea base (AS-IS) contra la cual se compararán los escenarios alternativos y la propuesta de mejora TO-BE más adelante.

16. Escenarios What-If

Aplicando la técnica de análisis de escenarios (comparación de configuraciones optimista, normal y pesimista), se construyeron tres escenarios What-If para el call center, manteniendo fijos el número de agentes (cuatro, configuración AS-IS) y el tiempo de servicio, y variando únicamente la tasa de llegada (λ) según el nivel de demanda observado en distintos periodos del año 2021.

El parámetro λ de cada escenario se estimó con el mismo método ya utilizado y validado previamente (la media de los tiempos entre llegadas observados), aplicado ahora a un subconjunto de datos en lugar de al año completo: el mes de enero para el escenario optimista (menor demanda), el año completo para el escenario normal, y el mes de diciembre para el escenario pesimista (mayor demanda). Para mantener los tres escenarios estrictamente comparables, el valor de λ de diciembre se recalculó con este mismo método (131.86 s en lugar de los 132.50 s utilizados anteriormente, una diferencia de apenas 0.5% sin efecto relevante sobre los resultados).

Escenario	λ (seg. entre llegadas)	Llamadas	Espera prom. (seg)	% cumple SLA	Utilización simulada
Optimista (enero)	250.38	3 000	3.87 ± 1.13	$97.84\% \pm 0.56\%$	29.9%
Normal (promedio anual)	180.58	4 309	12.53 ± 2.15	$93.83\% \pm 0.70\%$	41.2%
Pesimista (diciembre)	131.86	6 249	41.72 ± 5.67	$82.82\% \pm 1.51\%$	56.3%




Figura 8. Comparación de la espera promedio y el cumplimiento del SLA entre los tres escenarios (30 réplicas por escenario).

Los resultados muestran un deterioro no lineal del servicio a medida que aumenta la demanda: al pasar de enero a diciembre, el número de llamadas se duplica (de 3 000 a 6 249), pero el tiempo de espera promedio se multiplica por más de diez veces (de 3.87 a 41.72 segundos). Esto es consistente con el comportamiento típico de un sistema de colas: cuando la utilización de los servidores se aproxima a niveles altos, pequeños incrementos adicionales en la demanda generan aumentos desproporcionados en los tiempos de espera. Con cuatro agentes fijos, solo el escenario optimista (enero) cumple holgadamente el objetivo del 90%; el escenario normal se ubica ligeramente por debajo (93.83%, aunque dentro de los límites aceptables); y el escenario pesimista incumple de forma clara el estándar (82.82%). Esto confirma que la capacidad actual de cuatro agentes es adecuada para una demanda baja o promedio, pero insuficiente para los periodos de alta demanda.

como el de diciembre, lo que motiva la propuesta de mejora TO-BE desarrollada en la sección siguiente.

17. Propuesta TO-BE

La mejora propuesta para el proceso TO-BE consiste en aumentar el número de agentes disponibles durante los periodos de alta demanda, manteniendo sin cambios el resto del proceso (disciplina FIFO, canal telefónico único, estándar de servicio de 60 segundos). Esta alternativa es directamente evaluable con el mismo motor de simulación ya validado, cambiando únicamente el parámetro n_{agentes} .

Se simuló el escenario pesimista (demanda de diciembre, la de mayor exigencia) con un número creciente de agentes, de 4 (configuración AS-IS) hasta 8, ejecutando 30 réplicas por cada configuración, con el fin de identificar el número mínimo de agentes que permite cumplir el criterio de éxito definido previamente ($\geq 90\%$ de llamadas atendidas en 60 segundos o menos).

N° de agentes	Espera prom. (seg)	% cumple SLA	Utilización simulada	¿Cumple objetivo ($\geq 90\%$)?
4 (AS-IS)	43.17 ± 5.17	$82.39\% \pm 1.03\%$	56.9%	No
5 (TO-BE propuesto)	10.51 ± 1.82	$94.43\% \pm 0.72\%$	45.5%	Sí
6	2.62 ± 0.62	$98.43\% \pm 0.34\%$	37.9%	Sí
7	0.62 ± 0.27	$99.61\% \pm 0.17\%$	32.5%	Sí
8	0.14 ± 0.10	$99.92\% \pm 0.07\%$	28.5%	Sí




Figura 9. Sensibilidad del cumplimiento del SLA y del tiempo de espera al número de agentes, bajo la demanda de diciembre.

El resultado es contundente: agregar un único agente adicional (de 4 a 5) es suficiente para que el call center pase de incumplir claramente el estándar (82.39%) a superarlo con margen (94.43%), y reduce el tiempo de espera promedio de 43.17 a 10.51 segundos —una reducción de más de 75%—. A partir de 6 agentes, las mejoras adicionales son cada vez menores en términos relativos (rendimientos marginales decrecientes), lo que sugiere que agregar más de un agente no se justifica desde una perspectiva de costo-beneficio: el salto de 4 a 5 agentes resuelve el problema con el mínimo esfuerzo adicional posible.

Por lo tanto, la propuesta TO-BE consiste en incrementar la dotación de cinco agentes durante los periodos de alta demanda —en particular, a partir de septiembre, mes en el que el escenario AS-IS deja de cumplir el objetivo del 90%—, en lugar de mantener los cuatro agentes durante todo el año. Esta recomendación se cuantifica y compara formalmente contra el escenario AS-IS a continuación.

17.1. Diagrama BPMN del proceso TO-BE

El proceso TO-BE se modeló también en notación BPMN 2.0 (diagramas/bpmn_to_be.bpmn), incorporando el cambio propuesto respecto al AS-IS: se agregó un carril adicional, “Supervisor / Planificación”, con un flujo previo que verifica si el mes en curso corresponde a temporada de alta demanda (septiembre a diciembre) y, de ser así, activa el turno del quinto agente antes de que inicie la atención de llamadas del

periodo. El resto del flujo de atención (registro, verificación de disponibilidad, cola, atención, cierre y cálculo de indicadores) se mantiene igual que en el AS-IS, salvo que la tarea de cola de espera ya no se señala como cuello de botella crítico, sino como un punto de riesgo reducido gracias a la dotación ajustada.




Diagrama BPMN del proceso TO-BE de atención de llamadas (4 carriles: se agrega Supervisor/Planificación, encargado de activar el 5.º agente en temporada alta).

18. Comparación AS-IS versus TO-BE

Esta sección consolida la comparación cuantitativa entre el escenario actual (AS-IS, cuatro agentes) y la propuesta de mejora (TO-BE, cinco agentes), ambos evaluados bajo la misma demanda —la de diciembre de 2021, el mes más exigente del año—, siguiendo la estructura solicitada en la Actividad 10 del examen final: indicadores antes y después, impacto en tiempos de espera, impacto en utilización, impacto en throughput, viabilidad de implementación y recomendación final.

18.1. Indicadores antes y después

Indicador	AS-IS (4 agentes)	TO-BE (5 agentes)	Variación
Tiempo de espera promedio	43.17 seg	10.51 seg	-75.6%
% de llamadas dentro del SLA	82.39%	94.43%	+12.0 puntos porcentuales
Utilización de agentes	56.9%	45.5%	-11.4 puntos porcentuales
Llamadas atendidas (throughput)	6 249 de 6 249	6 249 de 6 249	Sin cambio

Comparación AS-IS vs. TO-BE — demanda de diciembre 2021




Figura 10. Comparación final AS-IS vs. TO-BE (demanda de diciembre 2021).

18.2. Impacto en tiempos de espera

El tiempo de espera promedio se reduce de 43.17 a 10.51 segundos, una disminución de 75.6%. Este es el impacto más directo y perceptible de la propuesta para el cliente: una llamada que en el escenario AS-IS esperaba, en promedio, más de dos tercios del propio estándar de servicio, en el escenario TO-BE espera solo una fracción de él.

18.3. Impacto en utilización

La utilización de los agentes baja de 56.9% a 45.5%. Esta reducción no debe interpretarse como un desperdicio de recursos, sino como el mecanismo mismo por el cual se logra la mejora: en un sistema con alta variabilidad (coeficiente de variación cercano a 1), mantener cierto margen de capacidad ociosa es lo que permite absorber las ráfagas de llamadas sin que se formen colas largas. Una utilización de 45.5% se considera razonable y no representa sobredimensionamiento severo del recurso.

18.4. Impacto en throughput

En ambos escenarios el sistema es estable (la utilización teórica es menor a 100%), por lo que la totalidad de las 6 249 llamadas de diciembre son finalmente atendidas tanto en el escenario AS-IS como en el TO-BE; el throughput en términos de volumen no cambia. La diferencia entre ambos escenarios no está en cuántas llamadas se atienden, sino en la calidad del servicio con que se atienden: en el AS-IS, una proporción importante de clientes espera más del estándar aceptable antes de ser atendida, mientras que en el TO-BE esa proporción se reduce sustancialmente.

18.5. Viabilidad de implementación

La propuesta TO-BE (incorporar un agente adicional durante los meses de alta demanda, de septiembre a diciembre según la tendencia identificada) es de baja complejidad de implementación: no requiere rediseñar el proceso, adquirir nueva tecnología, ni modificar el horario de atención al cliente; consiste en programar un turno adicional o reasignar personal existente durante el periodo identificado. El costo incremental de un agente adicional durante cuatro meses es considerablemente menor que el beneficio obtenido (una mejora de más de 12 puntos porcentuales en el cumplimiento del SLA y una reducción de más de tres cuartas partes en el tiempo de espera), lo que sustenta una relación costo-beneficio favorable, aun sin contar con datos de costo salarial real.

18.6. Recomendación final

Se recomienda implementar la propuesta TO-BE, incorporando un quinto agente durante los meses de mayor demanda (a partir de septiembre), en lugar de mantener la dotación fija de cuatro agentes durante todo el año. Dado que el análisis mensual muestra una tendencia de crecimiento sostenido en el volumen de llamadas a lo largo de 2021, se recomienda además que la organización reevalúe periódicamente este dimensionamiento con datos más recientes, ya que si la demanda continúa creciendo, la configuración de cinco agentes podría eventualmente volverse insuficiente, de la misma forma en que la configuración original de cuatro agentes dejó de serlo durante 2021.

19. Conclusiones

1. El problema planteado inicialmente —el deterioro progresivo del cumplimiento del estándar de servicio a lo largo de 2021— quedó confirmado con evidencia cuantitativa: el porcentaje de llamadas atendidas dentro de los 60 segundos cayó de 97.47% en enero a 83.45% en diciembre, mientras el volumen de llamadas se duplicaba, con una capacidad de atención que se mantuvo fija en cuatro agentes durante todo el periodo.

2. El modelo de simulación construido demostró un alto grado de validez: reprodujo el comportamiento real observado tanto en el mes de menor demanda (97.84% simulado frente a 97.47% real en enero) como en el de mayor demanda (84.09% simulado frente a 83.45% real en diciembre), con diferencias menores al 1%. Esta correspondencia en ambos extremos del rango de demanda respalda la validez del modelo para su uso en la evaluación de escenarios alternativos.

3. Se cumplieron tres de los cuatro criterios de éxito definidos previamente: el cumplimiento del SLA se restableció por encima del 90% (94.43% con la propuesta TO-BE); el tiempo de espera promedio se redujo en 75.6% respecto al escenario AS-IS simulado (y en 70.4% respecto al valor real observado en diciembre de 2021), superando ampliamente la meta de 50%; y se identificó el número mínimo de agentes adicionales necesario para lograrlo (uno solo, para un total de cinco).

4. El cuarto criterio —mantener la utilización de los agentes entre 70% y 85%— no se cumplió de forma estricta: la propuesta TO-BE opera con una utilización simulada de 45.5%. Este resultado no debe leerse como un error del modelo, sino como una conclusión válida en sí misma: dado que tanto las llegadas como los tiempos de servicio presentan una variabilidad alta (coeficiente de variación cercano a 1), sostener una utilización de 70-85% de forma consistente con ese nivel de variabilidad habría generado tiempos de espera considerablemente mayores a los aceptables, tal como lo anticipa la teoría de colas. En este caso, el objetivo de servicio (SLA) y el objetivo de eficiencia (utilización) entran en tensión, y el modelo prioriza el primero por ser el que motivó el problema original.

5. En términos generales, el trabajo demuestra que la simulación de eventos discretos permite anticipar, con evidencia cuantitativa y sin intervenir sobre la operación real, el efecto de una decisión operativa —en este caso, la incorporación de un agente

adicional— antes de implementarla, confirmando el valor de la simulación como herramienta de apoyo a la toma de decisiones.

20. Recomendaciones

20.1. Recomendaciones operativas para la organización

- Incorporar un quinto agente de atención durante los meses de mayor demanda (a partir de septiembre, según la tendencia identificada), en lugar de mantener la dotación fija de cuatro agentes durante todo el año.
- Monitorear mensualmente el porcentaje de cumplimiento del SLA y el volumen de llamadas, de forma que la organización pueda anticipar el momento en que la demanda vuelva a superar la capacidad instalada, en lugar de reaccionar una vez que el servicio ya se haya deteriorado.
- Evaluar una política de dotación variable por temporada (por ejemplo, cuatro agentes en el primer semestre y cinco en el segundo), en vez de una dotación fija todo el año, dado que el escenario optimista (enero) muestra que cuatro agentes son más que suficientes en periodos de baja demanda.
- Comunicar a los agentes y a los responsables del call center los hallazgos obtenidos, en particular que el objetivo no es maximizar la utilización de los agentes, sino sostener el nivel de servicio comprometido con los clientes.

20.2. Recomendaciones para extender el modelo en trabajos futuros

- Validar los parámetros y supuestos del modelo con un responsable real de la operación del call center, en caso de contar con acceso a dicha información.
- Incorporar datos de costo real por agente para transformar la recomendación en un análisis costo-beneficio cuantificado, en lugar de una argumentación cualitativa.
- Modelar explícitamente el abandono de llamadas (reneging) como un evento propio del sistema, en vez de tratarlo únicamente como un caso aislado de duración de servicio igual a cero.
- Actualizar el modelo con datos posteriores a 2021, dado que la tendencia creciente de demanda identificada en este trabajo sugiere que los parámetros de llegada podrían seguir cambiando en periodos más recientes.
- Explorar políticas de atención por prioridad o de dotación variable por hora del día, en lugar de un número fijo de agentes por mes, como una alternativa adicional a la propuesta TO-BE presentada en este trabajo.

21. Bibliografía

Bangs, D. (2021). Call Centre Queue Simulation [Conjunto de datos]. Kaggle.

<https://www.kaggle.com/datasets/donovanbangs/call-centre-queue-simulation>

Taha, H. A. (2017). Investigación de operaciones (10.^a ed.). Pearson Educación.